

AKBANK DERİN ÖĞRENMEYE GİRİŞ BOOTCAMPI

FİNAL RAPORU

HAZIRLAYAN:

Gurbet BUDAK

İSTANBUL-2025

ÖZET

Bu çalışmada, Intel Image Classification veri seti kullanılarak CNN tabanlı bir derin öğrenme modeli geliştirilmiştir. Modelin amacı, doğal ve yapay çevreyi temsil eden görselleri doğru sınıflara ayırarak otomatik sınıflandırma gerçekleştirmektir. Eğitim sürecinde model, eğitim ve doğrulama verileri üzerinde performansı dikkatle izlenerek optimize edilmiştir. İlk modelde eğitim doğruluğu %83.39, doğrulama doğruluğu %86.97 olarak elde edilmiş, eğitim kaybı 0.8574 ve doğrulama kaybı 0.7671 seviyesinde gerçekleşmiştir. Bu sonuçlar, modelin aşırı öğrenme göstermeden veri kümesini başarılı şekilde öğrendiğini ortaya koymaktadır.

Daha sonra, model dropout, batch normalization ve veri artırma (data augmentation) teknikleri ile geliştirilmiş ve dengeli bir öğrenme sağlanmıştır. Geliştirilmiş modelde eğitim doğruluğu %81.59, doğrulama doğruluğu %81.36, eğitim kaybı 0.5498 ve doğrulama kaybı 0.6103 olarak ölçülmüştür. Bu değerler, eğitim ve doğrulama arasındaki farkın minimum seviyeye indiğini ve modelin genelleme yeteneğinin iyileştirildiğini göstermektedir. Test seti üzerinde yapılan değerlendirmelerde, test doğruluğu %81.80, test kaybı ise 0.6103 olarak kaydedilmiştir. Sınıf bazlı performans analizleri, modelin özellikle forest sınıfında yüksek recall (%99) sağladığını, diğer sınıflarda ise precision, recall ve f1-score değerlerinin %76 ile %89 arasında değiştiğini göstermiştir.

Genel olarak elde edilen sonuçlar, CNN tabanlı derin öğrenme yöntemlerinin görsel veri sınıflandırma problemlerinde etkin ve güvenilir bir çözüm sunduğunu doğrulamaktadır. Model, sınıflar arası karışıklıkları minimum seviyede tutarken, farklı görüntü kategorilerini başarılı bir şekilde sınıflandırabilmiş ve hem eğitim hem de test verileri üzerinde dengeli bir performans göstermiştir.

İÇİNDEKİLER ÖZET.....	2
1. GİRİŞ	
1.1. Giriş	4
1.2. Çalışmanın Amacı ve Önemi?	5
1.3. Yapay zeka ve Derin Öğrenmeye Genel Bakış?	5
1.4. Yapay Sinir Ağları Nedir?	6
2. KULLANILAN YÖNTEMLER	
2.1. CNN'in nedir?	7
2.2. CNN'in Temel Özellikleri	7
2.3. CNN'in Çalışma Prensipleri	8
2.4. CNN'in Önemi ve Kullanım Alanları?	9
3. VERİ SETİ ve UYGULAMA	
3.1. Intel Image Classification	10
3.2. Kullanılan Araçlar	10
4. SONUÇ	
4.1. Değerlendirme	11
4.2. Gelecek Planları	12
KAYNAKÇA	13

1. GİRİŞ

1.1. Giriş

Günümüzde kullanılan yapay zekâ teknolojileri hızla gelişmekte ve doğru sonuçlar vermekte üstün başarı elde etmektedir. Son yıllarda yapılan çalışmalar da veri setinin büyüklüğü ya da çeşitli nedenler yapay zekaya ihtiyaç artmıştır. Finans, sağlık, eğitim, ulaşım gibi alanlar yapay zekanın kullanım alanlarından olup, hem iş süreçlerinde verimlilik artışı sağlanmakta hem de insanlara yeni hizmet olanakları sunulmaktadır. Yapay zekâ alt dallara ayrılmış olup bunlardan en duyarlı ve hassas sonuçlar veren makine öğrenmesi ve derin öğrenme yöntemleridir. Son yılların en çok tercih edilen doğruluğu yüksek yöntemlerdir. Özellikle derin öğrenme, çok katmanlı yapay sinir ağları aracılığıyla iç içe geçmiş karmaşık bağıntıları çözebilmekte ve büyük miktarda veriden öğrenmeyi mümkün kılmaktadır. Bu özellikleri sayesinde derin öğrenme, klasik makine öğrenmesi yöntemlerine kıyasla daha hassas, duyarlı ve yüksek başarı oranlarına sahip sonuçlar üretmektedir. Derin öğrenme, insan beyninden esinlenerek çalışan segmentasyon gibi işlemler de literatürde sıklıkla kullanılan yapay sinir ağıdır. Derin öğrenme mimarilerinden biri olan Convolutional Neural Network (CNN), özellikle görüntü işleme kısmında oldukça yüksek başarı göstermektedir. CNN'ler, girdi verisi üzerinde bulunan önemli öznitelikleri filtreler yardımıyla otomatik olarak çıkarabilmekte ve bu öznitelikleri sınıflandırma ya da tahmin süreçlerinde etkin bir şekilde kullanabilmektedir.

Bu rapor, Akbank tarafından düzenlenen Derin Öğrenmeye Giriş Bootcamp süreci kapsamında hazırlanmakta olup raporun amacı, derin öğrenme kavramını, CNN mimarisini ve bu teknolojilerin farklı sektörlerdeki kullanım alanlarını ele almaktadır. Ayrıca, bootcamp da edinilen bilgi ve deneyimleri aktarmaktır. CNN'in temel yapısı açıklanacak ve uygulama örneklerine yer verilecektir.

1.2. Çalışmanın Amacı ve Önemi

Görüntü işleme, dijital ortamdaki görüntüler üzerinde matematiksel ve algoritmik işlemler uygulayarak onları iyileştirme, analiz etme veya anlamlı bilgilere dönüştürme sürecidir. Görüntü işleme sayesinde ham verilerden nesne tanıma, sınıflandırma ve karar destek sistemleri gibi yüksek seviyeli çıktılar elde edilebilir. Bu alanın temel problemlerinden biri, görüntülerin otomatik olarak anlamlandırılması ve sınıflandırılmasıdır. Geleneksel makine öğrenmesi yöntemleri, bu tür yüksek boyutlu ve karmaşık verilerde etkili özellikler çıkarımında sıklıkla yetersiz kalmaktadır. Derin öğrenme, özellikle de Evrişimli Sinir Ağları (CNN'ler), bu probleme hiyerarşik özellik öğrenme yeteneği sayesinde çözümler getirmiştir. Bu çalışma Kaggle platformu üzerinden yürütülecek ve Kaggle uygulamasında paylaşılan Intel Image Classification veri seti üzerinde bir CNN tabanlı derin öğrenme modeli oluşturulacaktır. Çalışmanın amacı, Kaggle üzerinde seçilen veri seti kullanılarak bir derin öğrenme modeli geliştirmek ve bu süreçte veri kümesinin analizi, temel bir CNN mimarisinin tasarlanması, doğruluk ve diğer performans metriklerinin kullanılması ile aşırı öğrenmenin (overfitting) önlenmesi gibi adımların sistematik olarak uygulanmasıyla modelin yüksek doğrulukta sonuçlar vermesini sağlamaktır.

Bu çalışmanın önemi, derin öğrenme modeli geliştirme sürecinde adım adım gerçekleştirilen işlemleri öğrenmek ve bunları pratikte uygulayabilme becerisini kazandırmaktır. Veri ön işleme, model eğitimi, performans değerlendirmesi ve aşırı öğrenmenin (overfitting) önlenmesi gibi temel

kavram ve yöntemlerin öğrenilmesini sağlamaktadır. Çalışma sonucunda, katılımcının temel bir derin öğrenme mimarisi tasarlayabilecek düzeyde bilgi ve deneyim kazanması hedeflenmiştir; böylece ilerleyen projelerde daha karmaşık modeller oluşturmak için sağlam bir altyapı oluşturulmuş olacaktır.

1.3. Yapay zekâ ve Derin Öğrenmeye Genel Bakış

Günümüzde sıklıkla kullanılan yapay zekâ, insan beyninden esinlenerek ortaya çıkıp, problemlere çözüm üretme, tahminleme gibi işlemlerde kullanılmaktadır. Yapay zekâ alt dallara ayrılmış olup bunlardan en duyarlı ve hassas sonuçlar veren makine öğrenmesi ve derin öğrenme yöntemleridir. Son yılların en çok tercih edilen doğruluğu yüksek yöntemlerdir. Özellikle derin öğrenme, çok katmanlı yapay sinir ağları aracılığıyla iç içe geçmiş karmaşık bağıntıları çözebilmekte ve büyük miktarda veriden öğrenmeyi mümkün kılmaktadır.

Makine öğrenmesi, büyük ve karmaşık verilerin işlenmesinde yetersiz kalmış bu sayede derin öğrenme yöntemleri kullanılmış ve doğruluğu yüksek sonuçlar vermiştir. Yetersiz kalmasının bazı nedenleri: Doğrusal veya sınırlı karmaşıklığa sahip ilişkileri yakalamada başarılıdır; ancak verideki hiyerarşik ve çok katmanlı bağıntıları öğrenme kapasitesi sınırlıdır (i), genellikle veriden anlamlı özellikleri manuel olarak çıkarmaya bağımlıdır (ii), Veri miktarı arttıkça makine öğrenmesi algoritmalarının performansı genellikle sınırlıdır (iii).


Derin öğrenme modelleri büyük ve karmaşık verilerin işlenmesinde başarılı sonuçlar vermekte olan bir yapay zekâ mimarisidir. Bunun en büyük nedeni iç içe geçmiş bağıntılarının bulunması ve çok katmanlı olmasıdır. Özellikle CNN tabanlı mimariler, görüntü işleme de sıklıkla kullanılmaktadır. Derin öğrenme yöntemleri çok katmanlı olmasından kaynaklı verinin yüksek seviyeli temsillerini öğrenir ve manuel özellik çıkarımına gerek olmadan çözüm sağlar. Bu özelliği sayesinde özellikle karmaşık ve yüksek boyutlu veri türlerinde geleneksel makine öğrenmesine göre yüksek doğrulukta performans sergiler.

Derin öğrenme modellerinin temelini yapay sinir ağları oluşturur. Bu ağlar, insan beynindeki taklit ederek üç ana katmandan oluşur: girdi katmanı, gizli katmanlar ve çıktı katmanı. Girdi katmanı, modele veri sağlarken, gizli katmanlar verideki karmaşık ilişkileri öğrenir ve çıktı katmanı modelin tahminlerini üretir. Model, kendisine gelen girdileri ağırlıklarla çarpar ve aktivasyon fonksiyonları aracılığıyla işler; bu işlem zincirleme olarak katmanlardan çıktıya iletilir.

Derin öğrenmede farklı veri türleri ve problemler için geliştirilmiş çeşitli modeller bulunmaktadır. Bunlardan bazıları; Convolutional Neural Networks (CNN), özellikle görüntü işleme ve nesne tanıma problemlerinde yaygın olarak kullanılır. CNN'ler görüntüden otomatik olarak özellik çıkarabilir ve sınıflandırma için yüksek performans sunar. Recurrent Neural Networks (RNN), zaman serisi ve doğal dil işleme uygulamalarında geçmiş bilgiyi kullanarak tahmin yapma yeteneğine sahiptir. Generative Adversarial Networks (GAN) ise yeni veri örnekleri üretmek için kullanılır.

Derin öğrenme modellerinin temel avantajları arasında, otomatik öznitelik çıkarımı, karmaşık veri ilişkilerini öğrenebilme, büyük veri setlerinde yüksek doğruluk sağlayabilme ve transfer öğrenme ile önceden eğitilmiş modelleri farklı veri kümelerinde kullanabilme yer alır. Bu özellikler, derin


öğrenme modellerini özellikle görüntü sınıflandırma, nesne tespiti, tıbbi görüntüleme, otonom araç sistemleri ve finansal analiz gibi uygulamalarda vazgeçilmez kılmaktadır.



Şekil.2 Derin Öğrenme Yöntemleri

1.4. Yapay Sinir Ağları Nedir

Yapay sinir ağları, insan beynini taklit eden sistemler bütünüdür. Yapay sinir ağları yapay sinapslarla birbirine bağlanmış yapay nöronlardan oluşur. Yapay sinir ağlarındaki her bir nöron başka nöronlar tarafından kendisine iletilen bilgileri işler ve bulduğu sonucu başka nöronlara iletir. Derin sinir ağları, yapay sinir ağlarının bir türüdür.




Şekil.1 yapay sinir ağları

2. KULLANILAN YÖNTEMLER

2.1. CNN Nedir

CNN genellikle görüntü işlemede kullanılan ve girdi olarak görselleri alan bir derin öğrenme algoritmasıdır. Farklı operasyonlarla görsellerdeki özellikleri yakalayan ve onları sınıflandıran bu algoritma farklı katmanlardan oluşmaktadır.



Şekil.3 CNN Mimarisi

Convolutional (evrişim katmanı) CNN algoritmalarında görüntüyü ele alan ilk katmandır. Bilindiği üzere görseller aslında içlerinde belirli değerler taşıyan piksellerden oluşan matrislerdir. Evrişim katmanında da orijinal görsel boyutlarından daha küçük bir filtre görselin üzerinde gezer ve bu görsellerden belirli özellikleri yakalamaya çalışır.


2.2. CNN'in Temel Özellikleri

1. Yerel İlişkileri Yakalama

CNN, görüntüdeki kenar, köşe, renk ve şekil gibi anlamlı bilgileri otomatik olarak öğrenir. İnsan müdahalesine gerek kalmadan, görüntüdeki önemli detayları vurgular

2. Katmanlı Yapı:

CNN, girdi olarak bir görüntüyü alır ve bu görüntüyü işlem boyunca giderek daha soyut ve yüksek seviyeli özelliklere dönüştürür. İlk katmanlarda temel özellikler öğrenilirken, daha derin katmanlarda daha karmaşık ve soyut yapılar elde edilir.



Şekil.4 Konvolüsyon İşlemi

2.3. CNN'in Çalışma Prensipleri

CNN'ler, her biri bir giriş görüntüsünün farklı özelliklerini algılayan bir dizi katmana sahiptir. Amaçlanan amacın karmaşıklığına bağlı olarak, bir CNN düzinelerce, yüzlerce ve daha nadir durumlarda binlerce katman içerebilir ve her biri ayrıntılı desenleri tanımak için önceki katmanların çıktılarını temel alır.

Süreç, giriş görüntüsünün üzerine belirli özellikleri tespit etmek üzere tasarlanmış bir filtrenin kaydırılmasıyla başlar. Bu işleme evrişim işlemi denir; bu nedenle evrişimli sinir ağı adı da buradan gelir. Bu sürecin sonucu, görüntüdeki tespit edilen özelliklerin varlığını vurgulayan bir özellik haritasıdır. Bu özellik haritası daha sonra bir sonraki katman için girdi görevi görerek, bir CNN'nin görüntünün hiyerarşik bir temsiliyi kademeli olarak oluşturmasını sağlar.

1. Evrişimsel Katman

Evrişimsel katman, bir CNN'nin temel kısmıdır ve hesaplamaların çoğunun gerçekleştiği yerdir. Bu katman, belirli özelliklerin varlığını tespit etmek için bir giriş görüntüsünün alıcı alanında hareket etmek üzere bir filtre veya çekirdek (küçük bir ağırlık matrisi) kullanır.

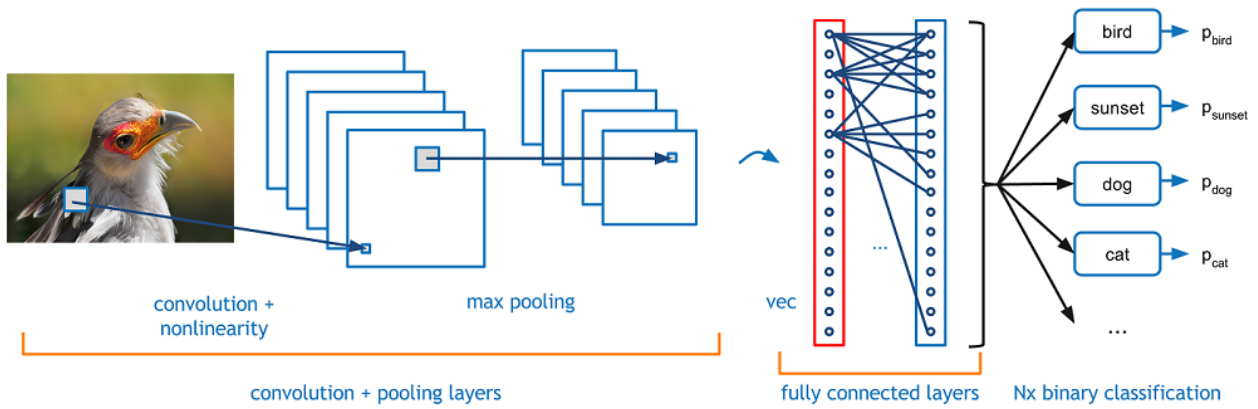
2. Havuzlama Katmanı

CNN'in havuzlama katmanı, evrişimsel katmanı takip eden kritik bir bileşendir. Evrişimsel katmana benzer şekilde, havuzlama katmanının işlemleri giriş görüntüsü üzerinde kapsamlı bir tarama işlemi içerir, ancak işlevi bunun dışında farklıdır. Havuzlama katmanı, kritik bilgileri korurken giriş verilerinin boyutunu azaltmayı ve böylece ağıın genel verimliliğini artırmayı hedefler. Bu, genellikle girişteki veri noktası sayısını azaltarak elde edilir.

3. Tam bağı katman

Tam bağlantılı katman, bir CNN'in son aşamalarında kritik bir rol oynar ve önceki katmanlarda çıkarılan özelliklere göre görüntüleri sınıflandırmaktan sorumludur. Tam bağlantılı terimi , bir katmandaki her nöronun bir sonraki katmandaki her nörona bağlı olduğu anlamına gelir. Tam bağlantılı katman, önceki evrişim ve havuzlama katmanlarında çıkarılan çeşitli özellikleri entegre eder ve bunları belirli sınıflara veya sonuçlara eşler. Önceki katmandan gelen her girdi, tam bağlantılı katmandaki her bir etkinleştirme birimine bağlanarak, CNN'nin nihai bir sınıflandırma kararı verirken tüm özellikleri aynı anda değerlendirmesini sağlar.

Aşağıda verilen kuş örneği CNN tabanlı bir derin öğrenme modelinin şemasını anlatmaktadır. Burada CNN mimarisi görüldüğü üzere nesne algılama, uzaktan algılama, tıbbi görüntü analizi, yüz tanıma gibi alanlarda kullanılabilir. Yüksek doğrulukta sonuçlar elde etmesi ve veri boyutunun düşük/yüksek olması, karmaşıklığını etkin bir şekilde yönetmesini sağlar.



Şekil.5 CNN Algoritma Şeması

2.4. CNN'in Önemi ve Kullanım Alanları

Convolutional Neural Networks (CNN), görsel verilerin işlenmesinde kullanılan bir derin öğrenme mimarisidir. Görüntüleri makine öğrenmesinden farklı olarak, uzamsal ilişkileri koruyarak işler. Bu sayede doğruluk oranı yüksek olmakta ve yaygın şekilde kullanılmaktadır. CNN'ler, katmanlar arasındaki ağırlıkları paylaşarak ve evrişim işlemleri ile filtreler aracılığıyla öznetelik çıkarımı yaparak, görüntüdeki kenar, doku, şekil ve renk gibi anlamlı özellikleri otomatik olarak tespit edebilir.

Bu mimari, sadece yüksek doğruluk sağlamakla kalmaz; görüntü verilerinin karmaşıklığını ve boyutunu yönetme yeteneği, modelin hesaplama kaynaklarını verimli kullanmasını ve aşırı öğrenme (overfitting) gibi sorunların azalmasını sağlar. Karmaşık verilerin çözülmesinde önemli rol oynaması, özellikle büyük veri setlerinde uygulanabilirliğini artırmaktadır.

CNN'in temel özellikleri arasında yerel ilişkileri yakalama yeteneği, ağırlık paylaşımı, havuzlama (pooling) katmanları ve derin öğrenme ile hiyerarşik özellik çıkarımı yer alır. Evrişim katmanları, görüntüdeki lokal öznitelikleri öğrenirken, pooling katmanları boyut indirgeme ve bilgi yoğunluğunu koruma işlevi görür. Bu sayede model, düşük seviyeli özniteliklerden (kenar, köşe, renk) başlayarak, üst katmanlarda daha karmaşık ve soyut özniteliklere (nesne, sahne yapısı) ulaşabilir.

CNN mimarisi, bu özellikleri sayesinde görüntü sınıflandırma, nesne tespiti, yüz tanıma, tıbbi görüntü analizi, otonom araç navigasyonu ve uzaktan algılama gibi birçok farklı alanda kritik bir rol oynamaktadır. Ayrıca, transfer öğrenme yöntemleri ile önceden eğitilmiş CNN modelleri, sınırlı veri ile yüksek performans elde etmek için kolayca uyarlanabilir ve pratikte büyük avantaj sağlar. CNN'ler, özellikle bilgisayarlı görü ve görüntü işleme alanlarında altın standart haline gelmiştir. Mimari olarak insan görsel korteksinden ilham almaları, görsel veri işlemede doğal bir üstünlük sağlamaktadır. Veri miktarının artması ve hesaplama gücünün gelişmesiyle birlikte, CNN tabanlı uygulamaların kullanım alanları genişlemeye devam etmektedir.

3. VERİ SETİ ve UYGULAMA

3.1. Intel Image Classification

Bu çalışmada kullanılan veri seti, Kaggle platformunda yer alan hazır *Intel Image Classification* veri setidir. Veri seti farklı sınıflara ait görüntülerden oluşmakta olup, sınıflandırma problemleri için yaygın olarak kullanılmaktadır. Veri setinde bulunan sınıflar şu şekildedir: Buildings, Bina ve şehir görüntüleri içeren sınıf türüdür. Forest, orman manzaraları içeren sınıf türüdür. Glacier, Buzullar, karlı manzaralar içeren sınıf türüdür. Mountain, dağ manzaraları içeren sınıf türüdür. Sea, deniz / okyanus sahneleri içeren sınıf türüdür. Street, sokak ve yol görüntüleri içeren sınıf türüdür. Bu sınıflar kullanılarak CNN tabanlı model oluşturulmuştur. Her bir görüntü boyutu 150x150 olup, 14000'den fazla görüntü bulunmaktadır.

3.2. Kullanılan Araçlar

Bu projede kullanılan veri seti, Kaggle platformunda hazır olarak sunulan Intel Image Classification veri setidir. Veri kümesi doğrudan Kaggle üzerinden temin edilerek, Kaggle'ın sağladığı bulut tabanlı çalışma ortamında işlenmiştir. Model geliştirme süreci boyunca Python programlama dili tercih edilmiş olup, özellikle derin öğrenme ve görüntü işleme için yaygın kullanılan kütüphaneler kullanılmıştır. NumPy ve Pandas veri analizi ve temel işlemlerinde kullanılırken, Matplotlib ve Seaborn görselleştirme işleminde kullanılmıştır. Projede Keras CNN tabanlı model tasarımı ve eğitiminden faydalanmıştır.

Geliştirme süreci boyunca Kaggle'ın sunduğu GPU hızlandırmalı donanım kullanılarak eğitim süresi kısaltılmıştır. CNN mimarisiyle birlikte aşırı öğrenmeyi engellemek için data augmentation, dropout ve batch normalization gibi yöntemlerden faydalanılmıştır. Model, eğitim ve doğrulama aşamalarının ardından test verisi üzerinde değerlendirilmiş ve sınıflandırma performansı ölçülmüştür.

4. SONUÇ

4.1. Değerlendirme

Bu çalışmada Kaggle üzerinde hazır olarak sunulan Intel Image Classification veri seti kullanılarak CNN tabanlı bir sınıflandırma modeli geliştirilmiştir. İlk olarak temel bir CNN mimarisi tasarlanmış ve modelin performansı incelenmiştir. Eğitim süreci sonunda model, eğitim verisinde %83.39 doğruluk, doğrulama verisinde ise %86.97 doğruluk elde etmiştir. Loss değerleri incelendiğinde eğitim kaybı 0.8574, doğrulama kaybı ise 0.7671 olarak ölçülmüştür. Bu sonuçlar, modelin veri kümesini başarıyla öğrendiğini ve aynı zamanda doğrulama seti üzerinde daha yüksek doğruluk göstermesiyle birlikte aşırı öğrenme sorununa sahip olmadığını ortaya koymuştur. Accuracy farkının-0.0358, loss farkının ise 0.0903 olması, modelin genelleme yeteneğinin tatmin edici düzeyde olduğunu göstermektedir.

Ardından, modelin daha dengeli ve güçlü bir öğrenme gerçekleştirmesi amacıyla geliştirilen bir CNN mimarisi uygulanmıştır. Bu geliştirilmiş modelde dropout, batch normalization ve veri artırma (data augmentation) gibi yöntemler kullanılarak aşırı öğrenmenin önüne geçilmeye çalışılmıştır. Sonuçlar incelendiğinde eğitim doğruluğu %81.59, doğrulama doğruluğu %81.36 olarak kaydedilmiş; eğitim kaybı 0.5498, doğrulama kaybı ise 0.6103 değerinde gerçekleşmiştir. Elde edilen bu değerler, eğitim ve doğrulama performansları arasındaki farkın neredeyse sıfıra indiğini göstermiştir. Nitekim accuracy farkı 0.0023, loss farkı ise -0.0605 olarak hesaplanmıştır. Bu durum, geliştirilen CNN modelinin neredeyse mükemmel bir şekilde genelleme yapabildiğini ve aşırı öğrenme problemini tamamen ortadan kaldırdığını göstermektedir.

Proje kapsamında geliştirilen CNN tabanlı modeller Intel Image Classification veri seti üzerinde başarılı bir sınıflandırma performansı sergilemiştir. İlk model yüksek doğruluk elde etmesine rağmen, geliştirilen ikinci modelin dengeli öğrenme ve güçlü genelleme yeteneği sayesinde daha güvenilir sonuçlar ortaya koyduğu görülmüştür. Bu bağlamda çalışma, çevresel görüntülerin sınıflandırılmasında derin öğrenme yöntemlerinin etkili ve uygulanabilir bir çözüm sunduğunu göstermektedir.

Yapılan çalışma kapsamında ilk model ve geliştirilen yeni model performans açısından karşılaştırılmıştır. Elde edilen sonuçlara göre, eğitim doğruluğu önceki modelde %82.78 iken yeni modelde %81.59 olarak ölçülmüştür. Eğitim doğruluğunda küçük bir düşüş gözlense de, asıl hedef olan doğrulama performansında ciddi bir iyileşme elde edilmiştir. Önceki modelin doğrulama doğruluğu yalnızca %62.93 iken, geliştirilen modelde bu oran %81.36'ya yükselmiştir. Bu durum, modelin genelleme gücünün büyük ölçüde arttığını göstermektedir. Ayrıca overfitting (aşırı öğrenme) farkı önceki modelde 0.1984 iken, yeni modelde 0.0023'e kadar düşmüş ve 0.1961 oranında iyileşme sağlanmıştır. Bu değerler, geliştirilen CNN modelinin dengeli bir öğrenme gerçekleştirdiğini ve aşırı öğrenme problemini ortadan kaldırdığını kanıtlamaktadır.

Geliştirilmiş model test verisi üzerinde de değerlendirilmiş ve %81.80 doğruluk oranı ile başarılı sonuçlar elde edilmiştir. Test loss değeri 0.6103 olarak ölçülmüştür. Sınıf bazlı performans incelendiğinde, modelin farklı kategorilerde tatmin edici sonuçlar verdiği görülmektedir. Özellikle

forest sınıfında %99'a varan recall oranı ile oldukça yüksek bir başarı yakalanmıştır. Buildings, glacier, mountain, sea ve street sınıflarında ise precision, recall ve f1-score değerlerinin %76 ile %89 arasında değiştiği tespit edilmiştir. Genel olarak model, tüm sınıflar için dengeli bir performans ortaya koymuş ve ortalama doğruluk değeri %82 olarak hesaplanmıştır.

Sonuçlar değerlendirildiğinde, geliştirilen CNN modelinin yalnızca eğitim verisine odaklanmadan, doğrulama ve test verileri üzerinde de yüksek başarı sağladığı görülmektedir. Bu durum, modelin pratik uygulamalarda güvenle kullanılabilecek düzeyde genelleme yeteneğine sahip olduğunu göstermektedir.

Bu çalışmada CNN tabanlı model için çeşitli hiperparametre kombinasyonları denenmiş ve en uygun mimari yapı belirlenmiştir. Denemeler sonucunda en iyi performansı veren modelde birden fazla evrişim katmanı, belirli kernel boyutları ve farklı dropout oranları kullanılmıştır. Ayrıca yoğun katmanda belli sayıda nöron tercih edilmiş ve öğrenme sürecini optimize etmek amacıyla uygun bir optimizasyon algoritması ile öğrenme oranı belirlenmiştir. Bu yapı sayesinde modelin dengeli bir öğrenme gerçekleştirmesi sağlanmıştır.

Modelin performansını değerlendirmek amacıyla eğitim süreci boyunca doğruluk ve kayıp grafiklerinin görselleştirilmesi yapılmıştır. Bu grafikler, modelin öğrenme eğrisini ortaya koyarak eğitim sürecinde doğruluk oranlarının artışı ve kayıp değerlerinin azalmasını gözlemleme imkânı sağlamıştır. Bunun yanı sıra sınıflandırma performansını daha ayrıntılı incelemek amacıyla hata matrisi oluşturulmuş ve ısı haritası şeklinde görselleştirilmiştir. Bu analizler, modelin bazı sınıflarda güçlü bir performans sergilerken, bazı sınıflarda karışıklıkların yaşandığını göstermiştir.

Sonuç olarak, yapılan hiperparametre optimizasyonu ve görselleştirme çalışmaları sayesinde CNN tabanlı modelin performansı hem genel başarı düzeyi hem de sınıf bazlı değerlendirmeler açısından kapsamlı şekilde analiz edilmiştir. Bu süreç, yalnızca en iyi doğruluk değerine ulaşmayı değil, aynı zamanda modelin hangi sınıflarda daha güçlü ya da zayıf olduğunu ortaya koyarak bütünsel bir değerlendirme yapılmasını sağlamıştır.

4.2. Gelecek Planları

Bu bootcamp sürecinde temel düzeyde derin öğrenme, CNN mimarileri, veri ön işleme ve model değerlendirme yöntemleri hakkında önemli kazanımlar elde edilmiştir. Gelecekte bu çalışmayı daha ileri taşımak adına farklı yaklaşımlar uygulanabilir. Modelin performansını artırmak için hiperparametre optimizasyon teknikleri daha kapsamlı biçimde uygulanabilir.

Bunun yanı sıra, mevcut çalışma sadece sınıflandırma problemine odaklanmıştır. Gelecekte, daha geniş veri setleri üzerinde çalışılarak nesne tespiti (object detection) veya segmentasyon (segmentation) gibi daha ileri düzey bilgisayarla görme uygulamaları da gerçekleştirilebilir. Ayrıca geliştirilen model gerçek hayata entegre edilerek mobil uygulamalar veya web tabanlı servisler üzerinden kullanılabilir hale getirilebilir.

Kısacası, bu bootcamp süreci bir başlangıç noktası olmuş, temel bilgilerin üzerine inşa edilecek daha gelişmiş yapay zeka uygulamaları için sağlam bir altyapı oluşturmuştur.

KAYNAKÇA

<https://bartubozkurt35.medium.com/cnn-convolutional-neural-networks-nedir-a5bafc4a82a1>

<https://nyilmazsimsek.medium.com/derin-%C3%B6%C4%9Frenme-deep-learning-nedir-ve-nas%C4%B1l-%C3%A7al%C4%B1%C5%9F%C4%B1r-2d7f5850782>

<https://medium.com/@michalmikuli/the-secret-sauce-of-cnns-understanding-convolution-and-pooling-step-by-step-facd5a7e4e5f>

https://viso.ai/deep-learning/convolution-operations/?utm_source=chatgpt.com

<https://www.techtarget.com/searchenterpriseai/definition/convolutional-neural-network>

<https://devhunteryz.wordpress.com/2018/04/08/evrisimsel-sinir-aglariconvolutional-neural-network/comment-page-1/>

<https://bilimgenc.tubitak.gov.tr/yapay-sinir-aglari-nedir#:~:text=Benzer%20bi%C3%A7imde%20yapay%20sinir%20a%C4%9Flar%C4%B1,yapay%20sinir%20a%C4%9Flar%C4%B1n%C4%B1n%20bir%20t%C3%BCr%C3%BCd%C3%BCr.>